

"Oxford Parkinson's Disease Telemonitoring Dataset"

1. Introdução

A doença de Parkinson é a segunda doença neurodegenerativa mais comum do mundo e afeta entre 7 a 10 milhões de pessoas. Manifesta-se em média aos 55 anos, aumentando significativamente a prevalência com a idade.¹ Cerca de 89 % das pessoas que apresentam doença de Parkinsons revelam perturbações vocais, sendo os sintomas comuns, a redução do volume da fala (disfonia) e problemas de articulação e fluência (disartria). As perturbações de fala, nestes casos, aparecem devido a um défice da função laríngea, ao desempenho deficiente dos músculos faciais, a uma diminuição da capacidade vital dos pulmões e uma diminuição do impulso da fala. ² A gravação de voz é realizada de forma não invasiva, é bastante simples e apresenta como grande vantagem o facto de o doente não necessitar de se deslocar da sua residência. Para além disso, estas gravações também podem ter aplicações nas avaliações em telemedicina. Este projeto apresenta como objetivo o diagnóstico de doentes de Parkinson, com base em gravações de voz, utilizando técnicas de Classificação Supervisionada.

2. Conjunto de dados

```
[1]: # Importação das bibliotecas

import numpy as np
import pandas as pd
%matplotlib inline
import matplotlib.pyplot as plt
from data_profiling import ProfileReport
import seaborn as sns
```

2.1. Informação do conjunto de dados

Este projeto apresenta como conjunto de dados escolhido, Parkinsons Telemonitoring Data Set, que se encontra disponível na UCI Machine Learning Repository. É constituído por gravações de voz de 42 pessoas com doença de Parkinson em fase inicial, que foram selecionadas para um teste de 6 meses através de um dispositivo de telemonitorização para monitorização remota da progressão dos sintomas. De notar que as gravações foram automaticamente capturadas nas residências dos doentes. Este conjunto de dados, apresenta um tamanho total de 5875 amostras e 22 características (features), sendo que, 16 são medidas biomédicas da voz. De notar que, todas as amostras são do tipo float64, excepto as colunas 'subject#', 'age' e 'sex' que são do tipo int64.